



MACHINE LEARNING CON PYTHON

TEMA 6. APRENDIZAJE
SUPERVISADO: REGRESIÓN Y
CLASIFICACIÓN



Contenidos Tema 6

- / 1. Aprendizaje Supervisado I: Regresión
- / 2. Aprendizaje Supervisado II: Clasificación
- / 3. Evaluación y validación de modelos de ML


ENLACE A GITHUB CON LOS MATERIALES:

<https://github.com/IconoTC/Machine-Learning-con-PYTHON>

REPOSITORIO DE DATASETS PARA EL CURSO: <https://github.com/gakudo-ai/open-datasets>

CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN


Regresión: aprender a predecir una variable numérica a partir de uno o varios atributos predictores



**House
attributes**



**Regression
Model**



Price




A dark blue icon of a price tag with a small circle at the top.

CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión lineal simple: Tal vez el modelo de ML supervisado más sencillo de todos

- Estimar variable numérica de salida y a partir de una variable de entrada x , asumiendo una relación lineal entre ambas.

$$\hat{y} = mx + n$$




CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión lineal simple: Tal vez el modelo de ML supervisado más sencillo de todos

- Estimar variable numérica de salida y a partir de una variable de entrada x , asumiendo una relación lineal entre ambas.

$$\hat{y} = mx + n$$





El modelo aprendido es la **función de una línea recta**, caracterizada por dos parámetros (m , n). Será mejor cuanto más fielmente se ajuste dicha línea a un conjunto de datos de entrenamiento (puntos)

CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión lineal simple: Tal vez el modelo de ML supervisado más sencillo de todos

- Estimar variable numérica de salida y a partir de una variable de entrada x , asumiendo una relación lineal entre ambas.

$$\hat{y} = mx + n$$




CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión lineal múltiple: Estimar variable numérica de salida y , a partir de n variables de entrada $x_1, x_2, \dots, x_n$, asumiendo una relación lineal:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- Modelo definido por $n+1$ parámetros o pesos θ_j
- El modelo pasa de ser una recta en 2D a ser un plano o, de forma más general, un hiperplano $(n+1)$ dimensional




CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión lineal múltiple: Estimar variable numérica de salida y , a partir de n variables de entrada $x_1, x_2, \dots, x_n$, asumiendo una relación lineal:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- Modelo definido por $n+1$ parámetros o pesos θ_j
- El modelo pasa de ser una recta en 2D a ser un plano o, de forma más general, un hiperplano $(n+1)$ dimensional



<i>Tipo de parámetro</i>	<i>Notación</i>	<i>Descripción</i>
Pesos o importancia de los atributos (feature weights)	$\theta_1, \dots, \theta_n$	Un peso θ_j asociado a cada variable predictora. Un mayor peso indica que esa variable es más influyente en las predicciones del modelo.
Término de sesgo (bias term)	θ_0	Necesario para ajustarse a datos de entrenamiento que no pasen por el origen $(0, \dots, 0)$.

EL PROCESO INTERNO DE ENTRENAMIENTO DE UN MODELO

Objetivo: minimizar error en predicciones, definido por **función de pérdida (loss function)** $J(\theta)$:

- Diferencia entre valor real y , y predicción, $\hat{y} = \hat{y}(\theta)$.
- Se realiza el promedio sobre m predicciones de test.

MAE: *Mean Absolute Error* - usar cuando los datos contengan muchos *outliers* →

$$MAE = \frac{1}{m} |\hat{y}^{(i)} - y^{(i)}|$$

RMSE: *Root Mean Square Error* - más “pesimista” pero eficaz penalizando malas predicciones →

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2}$$

R² (Coeficiente de determinación): muy interpretable para evaluar el rendimiento, pues es una métrica que buscamos maximizar, a diferencia del error.

- Usar cuando necesitemos interpretabilidad


$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

R²: Coefficient of Determination
Σ: Summation
y_i: Actual Values
ŷ_i: Predicted Values
ȳ: Mean of Actual Values

EL PROCESO INTERNO DE ENTRENAMIENTO DE UN MODELO

Optimización por descenso de Gradiente

- Encontrar un conjunto de parámetros θ que minimicen la pérdida $J(\theta)$:
- Mediante cálculo de derivadas, acercarse todo lo posible al mínimo de la función de pérdida





EL PROCESO INTERNO DE ENTRENAMIENTO DE UN MODELO

Optimización por descenso de Gradiente

- Encontrar un conjunto de parámetros θ que minimicen la pérdida $J(\theta)$:
- Mediante cálculo de derivadas, acercarse todo lo posible al mínimo de la función de pérdida

Stochastic Gradient Descent (SGD)


Añade aleatoriedad al proceso de optimización, haciéndolo más eficaz para grandes datasets complejos y funciones de pérdida donde podría haber mínimos locales.




EL PROBLEMA DEL SOBREAJUSTE (OVERFITTING)

Aprender en exceso de los datos de entrenamiento podría no ser precisamente algo bueno


- “Memorizar” en lugar de aprender patrones generalizables a futuros ejemplos de datos no vistos durante el entrenamiento → sobreajuste
- Un buen modelo es el que no solo aprende de los datos de entrenamiento en sí, sino que es capaz de generalizar a futuros datos




Underfitted




Good Fit/Robust




Overfitted



High training error
High test error



Low training error
Low test error




Low training error
High test error


EL PROBLEMA DEL SOBREAJUSTE (OVERFITTING)

¿Cómo combatir el sobreajuste?


- **Simplificar el modelo:** elegir un tipo de modelo con menos parámetros, reducir atributos en el *dataset*, o restringe su capacidad de aprendizaje mediante técnicas de regularización.
- Recolectar más datos de entrenamiento
- Reducir el ruido en los datos de entrenamiento disponibles: errores e inconsistencias, *outliers*.






Underfitted



Good Fit/Robust



Overfitted

High training error
High test errorLow training error
Low test errorLow training error
High test error

EL DILEMA SESGO-VARIANZA (BIAS-VARIANCE TRADEOFF)

El error cometido por un modelo de ML a la hora de generalizar su capacidad predictiva a futuros datos puede deberse a varios factores, entre los que destacan dos: sesgo y varianza.

¿Qué es el sesgo (bias) de un modelo de ML?

- Un factor conducente a errores, debido a que el modelo ha realizado asunciones incorrectas sobre los datos, a raíz de los datos de entrenamiento.
- Por ejemplo, asumir que los datos son de naturaleza lineal cuando en realidad se asemejan más a una naturaleza cuadrática.
- Un modelo con alto sesgo es propenso a un mal ajuste a los datos de entrenamiento (underfitting).

EL DILEMA SESGO-VARIANZA (BIAS-VARIANCE TRADEOFF)

El error cometido por un modelo de ML a la hora de generalizar su capacidad predictiva a futuros datos puede deberse a varios factores, entre los que destacan dos: sesgo y varianza.

¿Qué es la varianza de un modelo de ML?

- Un factor conducente a errores, ya que el modelo entrenado es muy sensible a pequeñas variaciones en los datos de entrenamiento.
- Habitual en modelos con más parámetros o grados de libertad, p.ej. regresión polinomial de alto grado (los veremos en breve).
- Efecto común en modelos de alta varianza → sobreajuste (overfitting).

EN RESUMEN...


- (1) Aumentar la complejidad de un modelo → Mayor varianza y menor sesgo → Riesgo de *overfitting*
- (2) Entrenar un modelo muy simple → Mayor sesgo y menor varianza → Riesgo de *underfitting*

CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión polinomial: ¿Qué sucede cuando nuestros datos no se ajustan bien a una función lineal?

- Se puede “simular” una regresión lineal donde se creen nuevas variables que sean potencias (cuadrado, cubo, etc.) de las originales, e incluso productos entre éstas.

$$x^2_1, \dots, x^2_n, x^3_1, \dots, x^3_n, \dots, \\ x_1x_2, x_1x_3, \dots$$



CONSTRUCCIÓN Y ENTRENAMIENTO DE MODELOS DE REGRESIÓN

Regresión Lasso y Ridge: Son extensiones “naturales” de los modelos de regresión lineal, que incorporan la idea fundamental de la regularización para combatir el sobreajuste:

- Los **modelos más tradicionales** se entrenan guiados por el objetivo de **minimizar únicamente el error** (normalmente cuadrático)
- **En modelos polinomiales o lineales con muchos atributos**, esto suele aumentar el **riesgo de sobreajuste**.
- **Ridge (L2) y Lasso (L1)** son dos variantes que incorporan una función de penalización sobre los pesos que se van aprendiendo, para controlar su magnitud.

$$\min_{\beta} \|y - X\beta\|^2 + \alpha \|\beta\|_2^2$$

RIDGE (L2)

Penaliza pesos grandes de forma más suave que L1, sin llegar a reducirlos a 0

$$\min_{\beta} \|y - X\beta\|^2 + \alpha \|\beta\|_1$$

LASSO (L1)

Más agresivo, puede llegar a reducir algunos pesos a 0